Implémentez un modèle de scoring



PLE Coline



PROJET 7

04/12/2023

Plan de la présentation

- Présentation de la problématique et du jeu de données
- Présentation de la modélisation
- Présentation du pipeline de déploiement
- Présentation de l'analyse de la dérive des données
- Présentation /démo du dashboard interactif
- Discussion



RAPPEL DE LA PROBLEMATIQUE





PROBLEMATIQUE ET MISSIONS

Contexte:

Proposition de prêts à la consommation pour des clients ayant peu ou pas d'historique de prêts.

Besoins:


- Modèle de classification calculant la probabilité qu'un client rembourse ou non son crédit pour la prise de décision.
- Dashboard interactif pour un échange en toute transparence entre le chargé de relation client et le client.

Missions:

- Construction d'un modèle de scoring donnant une prédiction sur la probabilité de faillite d'un client de façon automatique.
- 2. Création du dashboard interactif à destination des gestionnaires de la relation client.
- 3. Mise en production du modèle de scoring à l'aide d'une API, et du dashboard appelant l'API pour les prédictions.

PRESENTATION DES JEUX DE DONNEES





PREPARATION DES JEUX DE DONNEES



Ensemble des jeux de données

- Elimination des variables non pertinentes, redondantes ou fortement corrélées.
- Multiplication par -1 de toutes les variables négatives.
- Gestion des valeurs manquantes: Imputation par -1 (catégorielles) et -2 (numériques)

6 jeux de données concernant l'historique des crédits




- 1 seul type d'agrégation par variable (hors Montants crédits)
- Encodage manuel des variables catégorielles

2 principaux jeux de données



- Regroupement au niveau des secteurs d'activités, des emplois et du statut familial.
- Encodage manuel de certaines variables catégorielles (sexe, accompagnement, possession d'un bien immobilier ou d'une voiture...).
- Encodage avec le OneHotEncoder pour les autres variables catégorielles.
- Création de nouvelles variables:
 - Age du client, du téléphone et de la voiture (années).
 - Ancienneté dans le dernier emploi (années).
 - Comptage du nombre de façons de joindre le client.
 - Nombre de documents fournis.
 - Montant de l'annuité par rapport au revenu total du client (%).
 - Montant de l'annuité par rapport au montant du crédit (%).
 - Montant du crédit par rapport au revenu total du client (%).

PRESENTATION DE LA MODELISATION: Métriques métiers et RFE-CV




Le score métier = Métrique de référence

Postulat: Cout d'un FN 10x > FP

$$\frac{10*FN+FP}{TP+TN+FP+10*FN}$$

Réduction du nombre de variables par RFE-CV (Random Forest Classifier -75000 clients)



Point d'inflexion/coude au niveau de 20 variables

→ Conservation des 30 premières variables



Déséquilibre des classes

92% de clients sans risque

8% de clients à risque

Mauvais apprentissage en ML

PRESENTATION DE LA MODELISATION:

Gestion du déséquilibre des classes



La gestion du déséquilibre des classes (Réalisée sur un Random Forest Classifier)

- SMOTE: Création synthétique d'échantillons dans la classe minoritaire.
- Oversampling: Sur-échantillonnage de la classe minoritaire.
- Undersampling: Sous-échantillonnage de la classe majoritaire.
- Attribution de poids différents aux 2 classes.


RFC weight 12	RFC weight 10	RFC weight 8	RFC weight 6	RFC weight 4	RFC weight 2	RFC undersampling	RFC oversampling	SMOTE	
RandomForestClassifier	RandomForestClassifier	RandomForestClassifier	RandomForestClassifier	RandomForestClassifier	RandomForestClassifier	Pipeline	Pipeline	Pipeline	Model
75.2507	78.0988	78.2867	78.189	79.1562	76.5559	49.6051	471.5283	788.2608	Training Time
90.5332	91.1446	92.3974	92.8949	94.39	94.6876	86.5476	94.366	82.1311	Train Accuracy
84.3016	84.7016	85.669	85.8755	86.8185	85.934	82.0805	87.4673	75.889	Test Accuracy
0.9688	0.9734	0.9789	0.9831	0.9871	0.9896	0.9489	0.9891	0.9171	Train AUC
0.7444	0.7459	0.7478	0.7496	0.7524	0.7516	0.7506	0.7477	0.715	Test AUC
0.9666	0.9679	0.9654	0.9668	0.9549	0.9526	0.9046	0.9695	0.9037	Train Recall
0.3966	0.3907	0.3635	0.3623	0.3372	0.3811	0.4699	0.3072	0.5106	Test Recall
0.459	0.4762	0.5156	0.5331	0.5951	0.6094	0.3654	0.5923	0.2992	Train Precision
0.2282	0.2331	0.242	0.2458	0.2579	0.2533	0.2176	0.2632	0.1697	Test Precision
0.6224	0.6383	0.6722	0.6872	0.7332	0.7433	0.5206	0.7353	0.4495	Train f1
0.2897	0.292	0.2906	0.2929	0.2923	0.3043	0.2974	0.2835	0.2548	Test f1
0.4747	0.4444	0.4141	0.3636	0.3131	0.2121	0.6061	0.5657	0.4545	Best threshold
0.1161	0.1093	0.0987	0.0929	0.0861	0.0847	0.1906	0.0768	0.2324	Train best score
0.4139	0.4129	0.4142	0.4131	0. 4 14	0.4072	0.4074	0.4182	0.4402	Test best score

CHOIX POUR LA GESTION DU DESEQUILIBRE DES CLASSES: Attribution d'un poids {0:1,1:2}

PRESENTATION DE LA MODELISATION: Gestion du déséquilibre des classes



La gestion du déséquilibre des classes: Le tracking sur MLFlow




PRESENTATION DE LA MODELISATION:

Gestion du déséquilibre des classes




La gestion du déséquilibre des classes: Le tracking sur MLFlow



Name	Value
Test AUC <u>✓</u>	0.752
Test Accuracy 🗠	85.93
Test Meilleur score metier 🗠	0.407
Test Precision 🗠	0.253
Test Recall 🗠	0.381
Test f1 <u>✓</u>	0.304
Train AUC 🗠	0.99
Train Accuracy 🗠	94.69
Train Meilleur score metier 🗠	0.085
Train Meilleur seuil 🗠	0.212
Train Precision 🗠	0.609
Train Recall 🗠	0.953
Train f1 🗠	0.743
Training Time 🗠	76.56

Metrics (14)



MODELISATION:

Test de 4 modèles avec les paramètres de base



10


Paramètres *:

- Séparation du trainset: 80% en train et 20% en test
- Standardisation des données avec le MinMaxScaler()
- Random state = 42
- class_weight(s) = {0:1, 1:2} (LR, CatBoostClassifier, LGBMClassifier) / scale_pos_weight =2 (XGBClassifier)

	DummyClassifier	LogisticRegression	CatBoostClassifier	LGBMClassifier	XGBClassifier
Training Time	0.0081	8.1704	28.9202	1.2504	18.7926
Train Accuracy	91.9271	82.4433	84.1115	82.7786	83.5587
Test Accuracy	91.9272	82.5553	81.3456	82.1683	80.8676
Train AUC	0.5	0.6999	0.8652	0.8054	0.8676
Test AUC	0.5	0.7029	0.7677	0.7675	0.7616
Train Recall	0.0	0.3619	0.6885	0.5617	0.6985
Test Recall	0.0	0.3563	0.5223	0.5096	0.5156
Train Precision	0.0	0.1906	0.2936	0.2489	0.287
Test Precision	0.0	0.1902	0.2217	0.2287	0.2147
Train f1	0.0	0.2497	0.4117	0.345	0.4069
Test f1	0.0	0.248	0.3113	0.3157	0.3032
Best threshold	0.0808	0.2222	0.2121	0.2222	0.2121
Train best score	0.4676	0.4367	0.3141	0.3721	0.3146
Test best score	0.4676	0.4375	0.3961	0.3942	0.4018

MODELISATION:

Test de 4 modèles avec optimisation des paramètres




OPTIMISATION 1 (via GridSearchCV)	OPTIMISATION 2 (via GridSearchCV)
Logistic Regression random_state = 42, cv=5, scoring = scorer_metier, class_weight = {0:1, 1:2}, n_jobs=-1 C: [10, 20, 50, 100, 200] max_iter: [500, 1000, 2500, 5000]	Modèle peu performant de base Pas d'amélioration après recherche de meilleurs paramètres (cf slides supplémentaires)
CatBoostClassifier random_state = 42, cv=5, scoring = scorer_metier, class_weights = {0:1, 1:2}, n_jobs=-1, verbose=0	CatBoostClassifier random_state = 42, cv=5, scoring = scorer_metier, class_weights = {0:1, 1:2},
iterations: [50, 100, 200] depth: [2, 4, 8] learning_rate: [0.01, 0.05, 0.1]	iterations: [100, 200, 400, 1000] depth: [6, 8, 10] learning_rate: [0.005, 0.01, 0.05, 0.1]
LGBMClassifier random_state = 42, cv=5, scoring = scorer_metier, class_weights = {0:1, 1:2}, n_jobs=-1, objective = 'binary' learning_rate: [0.001, 0.01, 0.05, 0.1] n_estimators: [25, 50, 100, 200] num_leaves: [4, 8, 16, 32]	LGBMClassifier random_state = 42, cv=5, scoring = scorer_metier, class_weights = {0:1, 1:2},
XGBClassifier random_state = 42, cv=5, scoring = scorer_metier, scale_pos_weight= 2, n_jobs=-1 learning_rate: [0.01, 0.05, 0.1] max_depth: [2, 4, 8] n_estimators: [50, 100, 200]	Modèle overfittant le plus Long à entraîner (cf slides supplémentaires)


MODELISATION: Choix du modèle final



	CatBoost Base auto_class_weight	CatBoost Base avec class_weight retenu	CatBoost 1 ^{ère} opt	CatBoost 2ème opt	LGBMC Base class_weight	LGBMC Baseavec class_weight retenu	LGBMC 1 ^{ère} opt	LGBMC 2 ^{ème} opt
Training Time	69.8722	70.6693	20.8735	70.2175	4.6839	3.4623	5.2072	15.2404
Train Accuracy	81.1421	84.1115	82.1933	82.755	80.801	* 82.7786	80.5299	83.8078
Test Accuracy	78.4482	81.3456	81.1115	80.3262	80.4042	* 82.1683	79.9294	80.4107
Train AUC	0.8857	0.8652	0.8172	0.8607	0.8032	0.8054	0.805	0.8967
Test AUC	0.7641	0.7677	0.7669	0.7688	0.7674	0.7675	0.7679	0.7679
Train Recall	0.7899	0.6885	0.6056	0.7024	0.5872	0.5617	0.6066	0.7774
Test Recall	0.5813	0.5223	0.5321	0.5432	0.5482	0.5096	0.5519	0.539
Train Precision	0.2709	0.2936	0.2506	0.2764	0.23	0.2489	0.2311	0.3036
Test Precision	0.2052	0.2217	0.2213	0.2153	0.2172	0.2287	0.2131	0.2152
Train f1	0.4034	0.4117	0.3545	0.3967	0.3306	0.345	0.3347	0.4367
Test f1	0.3034	0.3113	0.3126	0.3083	0.3112	0.3157	0.3075	0.3076
Best threshold	0.5354	0.2121	0.2121	0.202	0.596	0.2222	0.202	0.202
Train best score	0.296	0.3141	0.3611	0.3196	0.3784	0.3721	0.3737	0.2786
Test best score	0.3985	0.3961	0.3947	0.3969	0.3947	0.3942	0.397	0.3977

MODELISATION: Le tracking *via* MLFlow






MODELISATION: Le tracking *via* MLFlow




Métriques pour le LGBMClassifier retenu



Matrice de confusion et courbe ROC sur le test







MODELISATION:

Présentation du pipeline de déploiement



Lien du projet GitHub: https://github.com/colple/Implementez_un_modele_de_scoring





MODELISATION:



olin@Coline MINGW64 ~/Documents/Projet_Github/Implementez_un_modele_de_scoring


Writing objects: 100% (4/4), 401 bytes | 401.00 KiB/s, done. Total 4 (delta 3), reused 0 (delta 0), pack-reused 0

remote: Resolving deltas: 100% (3/3), completed with 3 local objects.
To https://github.com/colple/Implementez_un_modele_de_scoring.git

\$ git push origin main Enumerating objects: 7, done. Counting objects: 100% (7/7), done. Delta compression using up to 8 threads Compressing objects: 100% (4/4), done.

532a8f7..226f79e main -> main






16

LA DERIVE DES DONNEES: Présentation du datadrift



Dataset Drift Dataset Drift is NOT detected. Dataset drift detection threshold is 0.5						
30	8	0.267				
Columns	Drifted Columns	Share of Drifted Columns				

Data Drift Summary



LA DERIVE DES DONNEES: Présentation du datadrift





- Pas de dérive significative sur l'ensemble des variables.
- 8 dérives dont 1 assez conséquente (Montant de l'annuité par rapport au montant du crédit).

DASHBOARD INTERACTIF ET CONCLUSION



1. Version contenant les 48744 clients:

https://colple-implementez-un-m-applicationsstreamlit-interactif-e6beqf.streamlit.app/

2. Version ne comprenant que les 1000 premiers clients: https://implementezunmodeledescoring-vuwuspwad8k6jktck7tawc.streamlit.app/

CONCLUSION

- ✓ Elaboration d'un modèle de ML pour la décision automatique d'octroi ou non du prêt.
- ✓ Développement du tableau de bord interactif pour le chargé de clientèle.
- ✓ Déploiement via un pipeline continu.
- ✓ Axe d'amélioration:
 - Plus de données permettant de réduire la dérive des données (réentraînement du modèle).
 - Utilisation d'Hyperopt à la place de GridSearchCV (utilisation des connaissances acquises des essais précédents pour guider la recherche vers les combinaisons qui sont plus susceptibles d'être les meilleures).



- Débat / Réflexion -



Informations supplémentaires: Présentation du jeu de données



```
# Informations sur le jeu de données
bureau.info(verbose = True, show_counts = True)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1716428 entries, 0 to 1716427
Data columns (total 17 columns):
    Column
                            Non-Null Count
                                             Dtype
    SK ID CURR
                            1716428 non-null int64
    SK_ID_BUREAU
                            1716428 non-null int64
                                                           Encodage manuel (Sum | Count)
    CREDIT_ACTIVE
                            1716428 non-null
                                             object
    - CREDIT--CURRENCY--
                           -1716428-non-null--object-
                                                           Min
    DAYS CREDIT
                            1716428 non-null int64
    CREDIT_DAY_OVERDUE
                            1716428 non-null int64
                                                                    Mean
    DAYS_CREDIT_ENDDATE
                            1610875 non-null float64
                                                         Min
    DAYS ENDDATE FACT
                            1082775 non-null float64
                                                                   Mean
    AMT CREDIT MAX OVERDUE 591940 non-null
                                             float64
    CNT_CREDIT_PROLONG
                            1716428 non-null int64
                                                           Sum
                                                                    Mean & sum
 10
    AMT CREDIT SUM
                            1716415 non-null float64
    AMT_CREDIT_SUM_DEBT
                            1458759 non-null float64
                                                         Sum
 11
    AMT CREDIT SUM LIMIT
                            1124648 non-null float64
                                                                    Mean
    AMT_CREDIT_SUM_OVERDUE
                           1716428 non-null float64
 14 CREDIT_TYPE
                                                            Regroupement des prêts
                            1716428 non-null object
--15 -- DAYS_CREDIT_UPDATE--
                           1716428 non-null int64
                                                                   Mean
 16 AMT_ANNUITY
                            489637 non-null float64
dtypes: float64(8), int64(6), object(3)
memory usage: 222.6+ MB
```

Informations supplémentaires: Présentation du jeu de données



```
# Informations sur le jeu de données
previous application.info(verbose=True, show counts=True)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1670214 entries, 0 to 1670213
Data columns (total 37 columns):
    Column
                               Non-Null Count
                                                Dtype
    SK ID PREV
                                1670214 non-null
    SK ID CURR
                               1670214 non-null int64
                                                            Encodage manuel (Count)
    NAME CONTRACT TYPE
                               1670214 non-null object
    AMT ANNUITY
                               1297979 non-null float64
    AMT APPLICATION
                               1670214 non-null float64
                                                                      Mean & sum
                               1670213 non-null float64
    AMT CREDIT
    AMT DOWN PAYMENT
                               774370 non-null float64
                                                               Mean
-7----AMT-GOODS_PRICE-----
                               1284699 non-null - float64
8 WEEKDAY APPR PROCESS START 1670214 non-null object
9----HOUR-APPR-PROCESS-START-----
                               1670214 non-null - int64--
10 FLAG_LAST_APPL_PER_CONTRACT 1670214 non-null object
-11 NFLAG LAST APPL IN DAY 1670214 non-null int64
    RATE DOWN PAYMENT
                               774370 non-null float64
                                                             Mean
13 -- RATE -INTEREST- PRIMARY-------5951 -non-null------float64
14 -- RATE_INTEREST_PRIVILEGED ----
                               -5951 non-null float64
    NAME CASH LOAN PURPOSE
                               1670214 non-null object
                                                            Encodage manuel (Count)
16 NAME CONTRACT STATUS 1670214 non-null object
                                                             Mean
    DAYS DECISION
                               1670214 non-null int64
18 - NAME- PAYMENT-TYPE------1670214 non-null--object-
-19 -- CODE-REJECT-REASON----
                           ----- 1670214 non-null-- object-
                                                            Encodage manuel (Count)
20 NAME TYPE SUITE
                               849809 non-null
                                                object
21 - NAME - CLIENT - TYPE ------ 1670214 -non-null -- object
22 NAME GOODS CATEGORY 1670214 non-null object
-23 - NAME PORTFOLIO ------ 1670214 non-null object
-24 NAME PRODUCT TYPE -------1670214 non-null object
25 CHANNEL TYPE ----- 1670214 non-null object
26 -- SELLERPLACE -AREA-----------1670214 -non-null---int64--
                               1670214 non-null object
27 NAME SELLER INDUSTRY
    CNT_PAYMENT
                               1297984 non-null float64
                                                             Mean
-29 - NAME-YIELD-GROUP-----------1670214-non-null--object-
    PRODUCT COMBINATION
                               1669868 non-null object
31 DAYS FIRST DRAWING 997149 non-null float64
                             --- 997149 non-null -- float64
32 DAYS FIRST DUE
                             --- 997149-non-null----float64
-33 -- DAYS- LAST-DUE-1ST-VERSION-
                               997149 non-null float64
34 -- DAYS_LAST_DUE-
                               997149 non-null float64
35 DAYS TERMINATION
36 NFLAG INSURED ON_APPROVAL
                                                            Most frequent
                                997149 non-null float64
dtypes: float64(15), int64(6), object(16)
memory usage: 471.5+ MB
```

Informations supplémentaires: Présentation du jeu de données



```
# Informations sur le jeu de données
                                                                                      # Informations sur le jeu de données
                                                                                      credit cards.info(verbose=True, show counts = True)
installments.info(verbose=True, show counts = True)
                                                                                      <class 'pandas.core.frame.DataFrame'>
<class 'pandas.core.frame.DataFrame'>
                                                                                      RangeIndex: 3840312 entries, 0 to 3840311
RangeIndex: 13605401 entries, 0 to 13605400
                                                                                      Data columns (total 23 columns):
Data columns (total 8 columns):
                                                                                           Column
                                                                                                                       Non-Null Count
                                                                                                                                         Dtype
     Column
                                Non-Null Count
                                                     Dtype
                                                                                           SK ID PREV
                                                                                                                       3840312 non-null int64
     SK ID PREV
                                                                                                                       3840312 non-null int64
                                13605401 non-null
                                                     int64
                                                                                           SK_ID_CURR
                                                                                           MONTHS BALANCE
                                                                                                                       3840312 non-null int64
 1
     SK ID CURR
                                13605401 non-null
                                                                                           AMT BALANCE
                                                                                                                       3840312 non-null
                                                                                                                                        float64
     NUM INSTALMENT VERSION 13605401 non-null float64
                                                                       Mean
                                                                                           AMT CREDIT LIMIT ACTUAL
                                                                                                                       3840312 non-null int64
                                13605401 non-null int64
     NUM--INSTALMENT--NUMBER
                                                                                       5
                                                                                           AMT DRAWINGS ATM CURRENT
                                                                                                                       3090496 non-null float64
     DAYS INSTALMENT
                                13605401 non-null float64
                                                                                           AMT DRAWINGS CURRENT
                                                                                                                       3840312 non-null float64
                                13602496 non-null float64
     DAYS ENTRY PAYMENT
                                                                                           AMT DRAWINGS OTHER CURRENT
                                                                                                                       3090496 non-null float64
                                                                       Mean
                                13605401 non-null float64
     AMT INSTALMENT
                                                                                           AMT DRAWINGS POS CURRENT
                                                                                                                       3090496 non-null float64
     AMT PAYMENT
                                                                      Mean
                                13602496 non-null float64
                                                                                           AMT INST MIN REGULARITY
                                                                                                                       3535076 non-null float64
                                                                                           AMT PAYMENT CURRENT
                                                                                                                       3072324 non-null float64
dtypes: float64(5), int64(3)
                                                                                           AMT PAYMENT TOTAL CURRENT
                                                                                                                       3840312 non-null float64
memory usage: 830.4 MB
                                                                                           AMT RECEIVABLE PRINCIPAL
                                                                                                                       3840312 non-null float64
                                                                                           AMT RECIVABLE
                                                                                                                       3840312 non-null float64
                                                                                       13
                                                                                                                       3840312 non-null float64
                                                                                           AMT_TOTAL_RECEIVABLE
                                                                                           CNT DRAWINGS ATM CURRENT
                                                                                                                       3090496 non-null float64
                                                                                           CNT DRAWINGS CURRENT
                                                                                                                       3840312 non-null int64
 # Informations sur le jeu de données
                                                                                           CNT_DRAWINGS_OTHER_CURRENT
                                                                                                                       3090496 non-null float64
 pos cash.info(verbose=True, show counts = True)
                                                                                           CNT DRAWINGS POS CURRENT
                                                                                                                       3090496 non-null float64
 <class 'pandas.core.frame.DataFrame'>
                                                                                           CNT INSTALMENT MATURE CUM
                                                                                                                       3535076 non-null float64
 RangeIndex: 10001358 entries, 0 to 10001357
                                                                                           NAME CONTRACT STATUS
                                                                                                                       3840312 non-null object
 Data columns (total 8 columns):
                                                                                       21 SK DPD
                                                                                                                       3840312 non-null int64
     Column
                          Non-Null Count
                                            Dtype
                                                                                       22 SK DPD DEF
                                                                                                                       3840312 non-null int64
                                                                                      dtypes: float64(15), int64(7), object(1)
     SK ID PREV
                          10001358 non-null int64
                                                                                      memory usage: 673.9+ MB
                          10001358 non-null int64
     SK ID CURR
     MONTHS BALANCE
                          10001358 non-null int64
     CNT INSTALMENT
                          9975287 non-null
                                           float64
                                           float64
     CNT INSTALMENT FUTURE
                          9975271 non-null
     NAME CONTRACT STATUS
                          10001358 non-null
                                           object
     SK DPD
                          10001358 non-null
                                           int64
                                                         Count
     SK DPD DEF
                          10001358 non-null int64
 dtypes: float64(2), int64(5), object(1)
 memory usage: 610.4+ MB
```

Informations supplémentaires: Résultats obtenus après la première optimisation



	DummyClassifier	LogisticRegression	CatBoostClassifier	LGBMClassifier	XGBClassifier
Training Time	0.0082	23.9292	8.6766	1.3275	57.8648
Train Accuracy	91.9271	82.2002	82.1933	80.5299	85.4415
Test Accuracy	91.9272	82.5196	81.1115	79.9294	81.131
Train AUC	0.5	0.7048	0.8172	0.805	0.9247
Test AUC	0.5	0.7073	0.7669	0.7679	0.7672
Train Recall	0.0	0.3745	0.6056	0.6066	0.8255
Test Recall	0.0	0.3738	0.5321	0.5519	0.5299
Train Precision	0.0	0.1917	0.2506	0.2311	0.3363
Test Precision	0.0	0.1954	0.2213	0.2131	0.2211
Train f1	0.0	0.2536	0.3545	0.3347	0.4779
Test f1	0.0	0.2567	0.3126	0.3075	0.312
Best threshold	0.0808	0.2222	0.2121	0.202	0.202
Train best score	0.4676	0.4348	0.3611	0.3737	0.2417
Test best score	0.4676	0.4328	0.3947	0.397	0.3952

Informations supplémentaires: La stabilité des variables



88 93 0 0 Success Tests Warning Fail Error All tests Number of Rows The number of rows is 48744. The test threshold is eq=3.08e+05 \pm 3.08e+04. ① Share of Out-of-Range Values DETAILS The share of values out of range in the column AGE is 4.1e-05 (2 out of 48744). The test threshold is eq=0 \pm 1e-12. perc 15k (1) Share of Out-of-Range Values DETAILS The share of values out of range in the column ANNUITY_INCOME_PERC is 2.05e-05 (1 out of 48744). The test threshold is eq=0 ± 1e-12. Share of Out-of-Range Values DETAILS The share of values out of range in the column REGION_POPULATION_RELATIVE is 2.05e-05 (1 out of 48744). The test threshold is eq=0 ± 1e-12. (!) Share of Out-of-Range Values **DETAILS** The share of values out of range in the column prev_type_loans is 2.05e-05 (1 out of 48744). The test threshold is eq=0 ± 1e-12.